



[데이터 품질 점검]



Task : 2.1.1 데이터 품질 점검

- 클래스 분포 · 결측 · 중복 · 형식 점검
 - Fraud_Type 분포(타겟변수), 중복값
 - 컬럼 타입 명시 분류 및 변환
 - 데이터 품질 점검(결측치)
 - 원본 데이터셋 기준 형식 검증
 - 문자열, DATETIME, IP/MAC주소 형식 검증
 - 음수 금액 점검
 - 날짜 현실성 점검
 - 고객 계좌 반복 & 그룹 누수 구조
 - Time_difference_seconds 정의탐색
 - 음수처리



실행 및 진행 사항 정리

- Fraud_Type 분포(타겟변수)

a~l : 이상거래 종류 / m : 정상거래

정상거래 99% 이상거래 1%로 매우 불균형 데이터

ratio_percent	
Fraud_Type	
a	0.0833
b	0.0833
c	0.0833
d	0.0833
e	0.0833
f	0.0833
g	0.0833
h	0.0833
i	0.0833
j	0.0833
k	0.0833
l	0.0833
m	99.0000

a	100
b	100
c	100
d	100
e	100
f	100
g	100
h	100
i	100
j	100
k	100
l	100
m	118800

- 컬럼 타입 명시 분류 및 변환

1. 자동 키워드 매칭 시 오분류 가능성이 있어 명세서 기준 명시 리스트로 고정

** First_time_iOS_by_vulnerable_user 컬럼은 0/1플래그이므로 범주형 데이터

taget_col(타겟변수) = Fraud_Type

datetime_cols(날짜 컬럼) = Customer_registration_datetime ~

timedelta_cols(시간 차이 컬럼) = Time_difference

nemeric_cols(숫자형 데이터컬럼) = Customer_Birthyear ~

categorical_cols(범주형 데이터 컬럼) = ID ~

2. 타입 변환

datetime 6종 → datetime64

First_time_iOS_by_vulnerable_user (플래그 유지) → int 64

Time_difference_seconds 생성 ⇒ timedelta(0days 00:00:00) → 초 단위 파생

3. 타입 정리표

	column	dtype	missing_count	unique_count	role
0	ID	object	0	120000	categorical
1	Customer_Birthyear	int64	0	55	numeric
2	Customer_Gender	object	0	2	categorical
3	Customer_personal_identifier	object	0	1769	categorical
4	Customer_identification_number	object	0	4101	categorical
...	...	...	...	...	...
60	Transaction_history_with_the_account	int64	0	18	numeric
61	First_time_iOS_by_vulnerable_user	int64	0	2	numeric
62	Fraud_Type	object	0	13	target
63	Transaction_resumed_date	datetime64[ns]	0	56200	datetime
64	Time_difference_seconds	float64	0	57507	timedelta

- 데이터 품질 점검

1. 컬럼별 dtype / 결측 / 고유값

	column	dtype	missing_count	missing_ratio	unique_count	unique_ratio
0	ID	object	0	0.0	120000	100.0000
1	Customer_Birthyear	int64	0	0.0	55	0.0458
2	Customer_Gender	object	0	0.0	2	0.0017
3	Customer_personal_identifier	object	0	0.0	1769	1.4742
4	Customer_identification_number	object	0	0.0	4101	3.4175
...	...	...	...	...	...	...
60	Transaction_history_with_the_account	int64	0	0.0	18	0.0150
61	First_time_iOS_by_vulnerable_user	int64	0	0.0	2	0.0017
62	Fraud_Type	object	0	0.0	13	0.0108
63	Transaction_resumed_date	datetime64[ns]	0	0.0	56200	46.8333
64	Time_difference_seconds	float64	0	0.0	57507	47.9225

결측치 / 중복값 0

- 형식 검증(원본 데이터셋 기준)

1. Time_difference 형식 위반 : 0건

2. IP/MAC 형식 위반 : 0건

- 음수 금액 점검

수치형 중 음수가 존재하는 컬럼이 있어 방향정보인지 오류 인지 확인

이체금액, 거래 전 잔액, 거래 후 잔액에 있는 음수는 오류가 아닌 **입출금 방향 / 마이너스 통장** 가능성 → 이후 부호 분리 후 절댓값 보존

	column	negative_count	negative_ratio_percent	min	max
2	Transaction_Amount	35817	29.8475	-382480000	406690000
0	Account_initial_balance	4152	3.4600	-47002364	378294259
1	Account_balance	1661	1.3842	-45756563	408024828

**** 다만 이체금액이 0원인데 거래 발생한 경우 확인 필요**

	count	ratio_percent
음수(<0)	23100	30.26
0	1278	1.67
양수(>0)	51961	68.07

- 날짜 현실성 점검

미래 연도까지 분포 돼있어 시간기반 분할 부적절, **층화 분할을 주력으로 선택**

	column	min_date	max_date	year_min	year_max
	Customer_registration_datetime	2003-01-11 03:41	2024-11-16 07:31:46	2003	2024
	Account_creation_datetime	2003-01-14 02:01:26	2024-12-01 17:06:38	2003	2024
	Transaction_Datetime	2003-01-25 22:20:34	2058-06-30 19:13:38	2003	2058
	Last_atm_transaction_datetime	2003-01-21 21:29:08	2058-06-17 12:34:39	2003	2058
	Last_bank_branch_transaction_datetime	2003-01-22 23:38:48	2058-06-24 12:21:34	2003	2058
	Transaction_resumed_date	2003-01-19 21:29:08	2058-05-15 01:14:42	2003	2058

- 고객/계좌 반복 & 그룹 누수 구조

같은 고객이 train/valid 양쪽에 들어가면 누수발생 → **층화 or 고객 단위 그룹 분할 결정 필요**

고유 고객 수: 4,101 고유 계좌 수: 4,101 고객당 평균 거래수: 29.3	사기 행 수: 1,200 사기에 등장한 고유 고객 수: 1,067 정상 · 사기 양쪽에 등장하는 고객 수: 966
고객당 계좌 수 분포:	
고객수	
Account_account_number	
1	4101

- Time_diifference_seconds 정의 탐색 (음수 처리)

명세서 기준 직전 거래와의 시간 차이(Time_diifference)에 음수값이 있어서 확인

```

음수 건수: 156
음수 최소(초): -1045256012.0
음수 최소(일 환산): -12097.9

count
Fraud_Type
m      154
a         2

dtype: int64
Time_difference  Time_difference_seconds
74  -11381 days +21:39:31      -983240429.0
84   -7993 days +05:48:41      -690574279.0
111  -8775 days +10:23:42      -758122578.0
208  -1971 days +07:08:21      -170268699.0
224  -1536 days +15:53:02      -132653218.0

```

직전 거래와의 시간차이가 음수일 경우 해석에 오류가 생겨서 Time_difference 컬럼이 정말 직전 거래와의 시간차이 데이터가 맞는지, 어떤 컬럼들간의 시간 차이인지 확인

pair	match_ratio_percent
Transaction_Datetime - Last_atm_transaction_da...	12.48
Transaction_Datetime - Last_bank_branch_transa...	12.42
Transaction_Datetime - Transaction_resumed_date	4.21
Transaction_resumed_date - Last_atm_transactio...	0.47
Transaction_resumed_date - Last_bank_branch_tr...	0.46

```

[계좌별 · 시각정렬 직전거래] 일치율: 6.14 %
[전체 · 시각정렬 직전행]   일치율: 2.05 %

```

확인 결과 데이터셋 내 Datetime 컬럼들과의 관계성이 매우 낮다고 나옴

Time_difference_seconds	
count	1.200000e+05
mean	7.578565e+05
std	2.003843e+07
min	-1.045256e+09
1%	2.250000e+02
5%	9.789500e+02
50%	9.169500e+03
95%	5.884124e+05
99%	3.198631e+07
max	3.214080e+07

Time_difference_seconds	
Fraud_Type	
a	3222.0
b	8815.0
c	8451.5
d	9166.0
e	8594.5
f	7411.5
g	8669.0
h	161564.0
i	9403.0
j	7126.5
k	6260.5
l	8218.0
m	9186.0

피쳐 가치를 판단했을때 a와 h를 구분 할 수 있는 피쳐로 판단해서 일단 보류

**** datetime 컬럼들로 복원 불가능한 합성 생성값이지만 유형별 중앙값에서 변별력이 있으므로 드롭하지 않고 보존**하고 직전 거래와의 시간차이값이 음수 156건(대부분 정상 m)은 비물리적이므로 **절댓값 대신 결측 처리**

- 음수 금액 처리

금액 관련된 컬럼에서 음수가 있는 경우를 부호 분리 및 절댓값 처리

출금/입금 이진 컬럼 생성 → 1=출금(음수 거래금액) 0=입금(0 이상 거래금액)

거래금액 절댓값 컬럼 생성

2	Transaction_Amount	35817	29.8475	-382480000
0	Account_initial_balance	4152	3.4600	-47002364
1	Account_balance	1661	1.3842	-45756563

	Transaction_Amount	Transaction_is_withdrawal	Transaction_Amount_abs
0	10000	0	10000
1	-25160000	1	25160000
2	20130000	0	20130000

 결과