

# [Baseline, 5가지 모델 비교 및 최종모델 선정]

## Task : 1주차 모델링

|       |                          |                                   |       |                    |
|-------|--------------------------|-----------------------------------|-------|--------------------|
| 3.0   | 분류 모델링 (Part B)          |                                   |       |                    |
| 3.1   | Baseline                 | 최빈값·규칙 / 13-class 한방              | W1    | Baseline 성능        |
| 3.2.1 | 2단계 계층 분류                | 1단계 정상 vs 사기 (Recall 우선, 위험점수 산출) | W1~2  | 1단계 모델             |
| 3.2.2 |                          | 2단계 사기 유형 (a~l) 다중분류              | W1~2  | 2단계 모델             |
| 3.3   | 이상탐지 점수 결합               | 정상만 학습 → 보조 피쳐                    | W2    | 이상점수 결합 모델         |
| 3.4   | 성능 평가                    | Macro-F1·클래스별 Recall·13×13 혼동행렬   | W2~W3 | 성능 평가 리포트          |
| 3.5   | 비용 기반 임계값 분석             | FN/FP 단가 비대칭 기대비용 곡선              | W3    | 임계값 분석표            |
| 3.6   | 오류 세그먼트 분석               | 오탐·미탐·오분류 집중 구간                   | W3    | 오류 세그먼트 분석         |
| 4.0   | 생성 AI 합성데이터 (Part B ↔ A) |                                   |       |                    |
| 4.1   | 생성 모델 학습                 | CTGAN 등, Fraud_Type 조건부           | W3    | 학습된 생성 모델          |
| 4.2   | 합성 데이터 생성                | 13유형 × 1,000건 → syn_submission    | W3    | syn_submission.csv |
| 4.3   | 증강 재학습                   | 증강 전/후 Macro-F1 비교                | W3    | 증강 전후 성능표          |



## 실행 및 진행 사항 정리

▼ 2026.06.29(월) ~ 07.03(금)

베이스라인 / 성능평가 / 임계값 / 오탐·미탐 분석 데이터: DAICON FSI 2024 (13-class, 정상 m + 사기 a~l) · 지표: Macro-F1(주), PR-AUC, 혼동행렬 등

| 작업 항목                        | 상태    |
|------------------------------|-------|
| 1. 베이스라인 & 5모델 비교            | 진행 완료 |
| 2. 2계층 계층분류 vs 한방(13-class)  | 진행 완료 |
| 3. 평가지표·시각화 + 튜터 피드백 반영      | 진행 완료 |
| 4. 성능·환경 이슈 해결 (WSL/GPU/스레드) | 진행 완료 |
| 5. 임계값 / 생성증강 / 이상탐지         | 진행 완료 |

### 1. 베이스라인 & 5모델 비교

- **목적 및 가설** : 단순 규칙, 더미부터 부스팅까지 난이도를 올려가며 학습해, 동일 검증셋에서 성능이 실제로 개선되는지 확인한다.
- **방법 · 선택 근거**
  - **Logistic** : 선형 모델 한계 증명용 / **RandomForest** : 부스팅 필요성 증명용 / **XGBoost** 는 같은 부스팅 계열
  - 불균형 보정: Logistic/RF/LightGBM은 `class_weight='balanced'` , XGBoost 는 `sample_weight` 로 동일 취지 적용.
  - 결측(4개 컬럼): 트리 모델(LightGBM)은 NaN 자체 처리, 선형/RF는 SimpleImputer 파이프라인으로 보완.
  - MostFrequent를 하한선(baseline)으로 뒀서 "학습이 진짜 의미 있는가"를 판별.

| 모델               | Macro-F1 |
|------------------|----------|
| LightGBM         | 0.649    |
| TwoStage(2계층)    | 0.612    |
| XGBoost          | 0.489    |
| RandomForest     | 0.224    |
| Logistic         | 0.124    |
| MostFrequent(더미) | 0.077    |

- lightgbm, twostage 최종 모델 선정 근거 macor-f1 2모델
1. 불균형 데이터라 **Accuarcy 지표는 다수 클래스에 의해 왜곡되고, Weighted-F1도 표본 크기 가중치 때문에 유사한 문제가 남는다.** Macro-F1은 클래스 크기와 무관하게 **모든 유형(소수 사기 유형 포함)을 동등하게 평가**하므로, 극단적 불균형·다중분류 상황인 본 프로젝트의 주 **평가지표로 채택**했다.
  2. XGBoost와 LightGBM은 같은 부스팅 계열이지만 현재 데이터 기준으로 LightGBM이 F1 스코어가 더 높게 나오므로 XGBoost 제외

## 2. 2계층 계층분류 vs 13-class

• **목적 및 가설:** 1단계(정상 vs 사기 이진, Recall 우선 / 부스팅 계열 유리) → 2단계(사기유형 a~i 다중분류 / 거리기반(KNN)이나 단순모델)로 나눈 계층 구조가, 13-class를 한 번에 푸는 "한방" 방식보다 유리한지 검증.

### • 방법 · 선택 근거

- 1단계는 놓친 사기(FN)를 2단계가 영영 못 잡으므로 Recall 우선 설계(위험점수 산출).
- "2단계만 보면 정확도 높다"는 착시를 피하려고 반드시 end-to-end로 평가.


### • 결과

- end-to-end Macro-F1: TwoStage ≈ 0.612 (동 실행 LightGBM 한방 0.649와 유사 수준).
- 오류 전파 분해: ① 영구미탐(1단계 FN 유래) ② 정상 오라우팅(1단계 FP 유래) ③ 유형 오분류(2단계) → 개선 우선순위는 1단계 Recall 관리.

| 2단계 모델       | Macro-F1 |
|--------------|----------|
| LightGBM(참고) | 0.640    |
| RandomForest | 0.573    |

| 2단계 모델   | Macro-F1 |
|----------|----------|
| Logistic | 0.475    |
| KNN      | 0.339    |

1단계 이진분류 = LightGBM / 2단계 다중분류(a~l) = LightGBM, KNN, Logistic, RandomForest



- 1, 2단계 전부 LightGBM으로 사용하는것이 Macro-F1값이 더 높다 ⇒ **2계층 계층분류 모델 LightGBM으로 확정**

## 결과 : 최종모델 : 1단계 LightGBM / 2단계 LightGBM 선정

### 3. 임계값, 생성증강, 이상탐지

### 3-1. 임계값 최적화

- **목적** : 미탐(FN)이 오탐(FP)보다 훨씬 비싸다는 FDS 원리를 숫자로 반영해 임계값을 "감"이 아니라 근거로 결정.
- **결과** : (실행 기준: 전체 데이터) 위험점수 품질 PR-AUC 0.9157 / ROC-AUC 0.9968. 임계값을 낮출수록 Recall↑·FP↑ 트레이드오프가 명확히 확인됨. 비용 최소 임계값은 Recall 목표 임계값보다 낮게(사기 더 많이 잡는 쪽) 형성.

#### 임계값 최적화


[품질지표] PR-AUC=0.9157 ROC-AUC=0.9968

[임계값 스weep]

| 임계값  | Recall | Precision | F1     | FP  | F  | N      | 총비용 |
|------|--------|-----------|--------|-----|----|--------|-----|
| 0.05 | 0.9729 | 0.2143    | 0.3513 | 920 | 7  | 1060.0 |     |
| 0.10 | 0.9574 | 0.2913    | 0.4467 | 601 | 11 | 821.0  |     |
| 0.15 | 0.9457 | 0.3547    | 0.5159 | 444 | 14 | 724.0  |     |
| 0.20 | 0.9380 | 0.4144    | 0.5748 | 342 | 16 | 662.0  |     |
| 0.25 | 0.9380 | 0.4745    | 0.6302 | 268 | 16 | 588.0  |     |
| 0.30 | 0.9302 | 0.5184    | 0.6657 | 223 | 18 | 583.0  |     |
| 0.35 | 0.9302 | 0.5647    | 0.7028 | 185 | 18 | 545.0  |     |
| 0.40 | 0.9186 | 0.6077    | 0.7315 | 153 | 21 | 573.0  |     |
| 0.45 | 0.8953 | 0.6453    | 0.7500 | 127 | 27 | 667.0  |     |
| 0.50 | 0.8876 | 0.6982    | 0.7816 | 99  | 29 | 679.0  |     |
| 0.55 | 0.8798 | 0.7252    | 0.7951 | 86  | 31 | 706.0  |     |
| 0.60 | 0.8721 | 0.7732    | 0.8197 | 66  | 33 | 726.0  |     |
| 0.65 | 0.8643 | 0.8051    | 0.8336 | 54  | 35 | 754.0  |     |
| 0.70 | 0.8333 | 0.8465    | 0.8398 | 39  | 43 | 899.0  |     |
| 0.75 | 0.8217 | 0.8833    | 0.8514 | 28  | 46 | 948.0  |     |
| 0.80 | 0.8101 | 0.9330    | 0.8672 | 15  | 49 | 995.0  |     |
| ...  |        |           |        |     |    |        |     |
| 0.95 | 0.7171 | 0.9893    | 0.8315 | 2   | 73 | 1462.0 |     |


[추천①: Recall>=0.9] 임계값=0.438 → {'임계값': 0.438, 'Recall': 0.9031, 'Precision': 0.6401, 'F1': 0.7492, 'FP': 131, 'FN': 25, '총비용': np.float64(631.0)}

[추천②: 비용최소] 임계값=0.370 → {'임계값': 0.37, 'Recall': 0.9302, 'Precision': 0.5854, 'F1': 0.7186, 'FP': 170, 'FN': 18, '총비용': np.float64(530.0)}



### 3-2. 생성증강 (CTGAN, SMOTE)

- **목적** : 유형당 ~80건뿐인 소수 사기유형을 보강.
- **결과** : (실행 기준: 전체 데이터) Macro-F1 0.6697 → **0.5656 (-0.10)**, 사기유형 평균 Recall 0.638 → 0.548. 즉 증강이 오히려 성능을 떨어뜨림 → few-shot 구간에서 CTGAN이 실제 분포를 못 배우고 노이즈를 생성한 것으로 해석. "시도 → 한계 확인"의 유효한 실험 결론.
- **이슈 해결** : 일부 컬럼이 object로 생성돼 LightGBM 오류 → 메타데이터에서 피처 전부 numerical 강제 + 생성물 숫자 강제 변환으로 해결. GPU 없는 팀원 대비 CUDA 자동감지 추가.



### 3-3. 이상탐지 (IsolationForest)

- **목적** : 라벨 없는 신종/변종 사기 대비 안전망(비지도).
- **결과** : IsolationForest 단독 PR-AUC 0.030 / ROC 0.704 (약함), LightGBM 지도 0.916 / 0.997, 앙상블 0.837 / 0.983. → 이상탐지는 단독 대체가 아니라 지도학습의 보완재.



**결과**

오류 인지 자료가 안올라감