

[중간보고서 PPT 제작 및 정리 / 피드백 정리]



Task : 피드백 정리

메인 튜터 피드백 - 신재춘 튜터

1. 데이터 EDA 및 전처리 피드백

- 전처리 파이프라인과 발견된 품질 이슈 5가지를 구체적으로 제시한 점 훌륭함
- Fraud_Type 13개 클래스별 특징을 파악하기 위한 EDA 보완 필요
 - 현재는 13개 클래스를 함께 분석한 것으로 판단 됨
 - 각 클래스별 유사성 및 특이점 파악
- 유형별 특징 규명(a~f)의 확신도 판단에 대한 근거를 구체적으로 제시 필요
 - 높음/중간/낮음을 나누는 기준 보완

2. 모델링 및 평가 피드백

- (p.18~22) Baseline → 대조군 → 부스팅 단계적 비교 과정을 통해 적합한 모델을 탐색하는 과정을 수행한 점 훌륭함
 - 하지만, 데이터가 극단적으로 불균형한 상태에서 단일 모델만으로 모든 클래스를 분류하는 것은 한계점이 있음
 - Fraud_Type 특성에 맞는 모델링 전략 고민 필요
 - 필요에 따라 규칙 기반 알고리즘과 ML 모델 결합 시도 권장
- (p.14) 파생변수 생성 근거와 유형 확정
 - `Amount_vs_monthly_max_ratio` : 거래 시점에는 해당 월이 종료되지 않아 '월간 최대 거래 금액'을 확정할 수 없음
 - 이는 미래 데이터를 참조하는 논리적 오류를 발생시킬 수 있으므로, 실제 시스템 운영 환경을 고려하여 산출 방식(예: 전월 기준 또는 현재 시점까지의 누적 최대값 등)에 대한 재검토 필요

- 전 항목의 서술이 "재확인", "스토리 보강", "가설을 계산 가능한 형태로 구현", "사실상 확정"으로 되어 있음
 - 이는 라벨을 이미 아는 전체 데이터에서 피처를 설계하고, 같은 데이터에서 잘 분리된다는 걸 근거로 채택하는 구조임
 - 진짜 근거가 되려면
 - (1) 시간 분할(train=과거, test=미래) 또는 홀드아웃/CV에서의 lift,
 - (2) 실제 모델에서의 **feature importance / SHAP 기여도**가 있어야 함

3. 결과 해석 및 보고 피드백

- 분석 목표 및 문제 정의에서 비용 비대칭 구조가 핵심임을 강조했으나, 실제 모델 비교 과정에서는 모델 성능 기준으로만 비교하고 있음
- 비용 기반의 최적화를 수행한다면 모델 비교 단계에서도 비용을 반영해서 비교하는 것이 타당함

4. 종합 피드백

- **정상 고객을 과도하게 막지 않으면서 vs 13개 사기 유형을 정확히 탐지**
 - '정상 고객을 과도하게 막지 않는다'와 '13개 사기 유형을 정확히 탐지'하는 것은 trade-off 관계가 될 수 있음
 - 각 문제의 구체적인 임계값 설정이 필요
 - 문제 해결의 핵심은 13개 사기 유형을 탐지하는 것이지, 13개 사기 유형을 탐지하는 최고의 모델을 만드는 것이 아님
 - 즉, ML 모델이 13개 사기 유형을 탐지하는 유일한 수단이 아님을 유의할 것
- 오류 비용의 비대칭 구조
 - **단순 정확도 최적화가 아닌 비용 기반 임계값 설계 필요**
 - 현재 미탐(FN)을 실제 피해액 약 1700만원 고정값 방식의 한계를 확인하고 개선하는 과정이 훌륭함
 - 다만, 실제 이상거래 탐지 시스템(FDS)이 가동되는 환경에서는 특정 거래의 이상 여부를 즉각적으로 판별하기 어렵다는 제약이 있음
 - 따라서 정답을 실시간으로 알 수 없는 운영 상황에서 해당 모델이 어떻게 적용되고 작동할지에 대한 구체적인 시나리오 설계 보완 필요

💬 메인 멘토 피드백 - 이규화 멘토

1. 데이터 EDA 및 전처리 피드백

- 데이터의 극단적 불균형을 확인하고 Macro_F1 으로 채택한 것이 인상적입니다. 데이터의 특성을 이해하고 판단을 내린 것이 좋습니다.
- 개인식별자 41%·계좌 24%가 여러 유형에 걸쳐 등장 → 그룹 누수 위험을 정량화해 group split 근거 확보한것은 좋은 판단으로 보입니다.
- 통계 엄밀성과 서비스 지향까지 정말 야심이 가득한게 느껴져서 좋습니다.
- 각 사기 유형 100건(0.083%)은 극도로 작은 표본입니다. 유형당 100건에서 나온 배수·중앙값은 우연 변동에 취약합니다. 이에 대한 대안이 조금 필요해 보입니다.

2. 모델링 및 평가 피드백

- 13클래스 통합검정에서는 대규모 표본 탓에 거의 모든 변수가 효과크기 negligible로 나오는데, 이걸 "정상 vs 사기 1:1 재검정"으로 다시 봐서 실질 신호를 건져낸건 좋은 방향인 것 같습니다.
- 파생변수 선정하고 및 근거를 제시해서 유형별 정량적 시그니처를 부여하는 방식은 정말 좋은 유형의 인사이트 발굴 방법론 입니다.
- group split을 설계했으니 누수 통제는 돼 있을 텐데 0.7103은 어디서 나온 데이터 수치 인지 인지가 잘 안되는 것 같습니다.
- 생성 AI로 합성 데이터를 만들어 성능 개선에 활용한다고 했는데, 중간 결과의 0.7103이 합성 데이터를 포함한 성능인지 아닌지가 안 보입니다. 합성 데이터를 train에만 넣고 검증/테스트는 실제 데이터로만 했는지가 핵심입니다. 여기가 틀리면 성능이 부풀려집니다.

3. 결과 해석 및 보고 피드백

- 비용기반 임계값 설계부분이 정말 대단할 정도로 이끌어낸 것 같습니다. Macro-F1만으로는 이 임계값을 실전에 써도 되는지 설명 못 한다 → 미탐(FN, 1,700만원/건)과 오탐(FP, 수천~수만원/건)의 비대칭 비용으로 임계값을 정한다는 논리는 실무 감각이 있어야 할 수 있는 판단으로 보입니다.
- 왜 이상거래인지 + 권장 조치를 자연어로 자동 생성은 매력적인데, RAG 특성상 환각(hallucination) 위험이 있습니다. 생성된 조치가 실제로 정확·안전한지 어떻게 담보하는지(근거 문서 인용, 사람 검수 단계)를 한 줄이라도 넣어야 합니다.

4. 종합 피드백

- 방법론·실무성·완성도를 가장 높은 수준으로 결합한 팀입니다.데이터 품질 이슈를 오류와 정보로 가려낸 판단, 대규모 표본에서 효과크기로 재검정한 통계 설계, 모델 구조를 직접 실험으로 반증하고 비용 비대칭으로 임계값을 정한 것. 하나하나가 실전에 근접해 있습니다.
- 최종 발표 까지 3가지 정도를 보충 하면 좋을듯 합니다.

1. **평가의 독립성:** 임계값 스캔과 합성 데이터가 평가셋에 스며들지 않았음을 명시하고, 0.7103이 어느 데이터의 수치인지 못박을 것
2. **성능의 해부:** 클래스별 F1(특히 취약한 d·g 유형)과 합성 데이터 QA 결과를 본문으로 끌어올려, Macro-F1 0.71의 구성을 투명하게 보일 것
3. **자동화의 책임성:** RAG 대응 매뉴얼의 환각 통제와 알림 시스템의 운영 부하를 한 장으로 다룰 것. 지금 궤도면 완성도는 이미 최상위권이고, 남은 건 '이 성능이 진짜다'와 '이 자동화가 안전하다'를 증명하는 마지막 검증하는 것입니다.



실행 및 진행 사항 정리

- 피드백 정리 :
 - EDA / 전처리 :
 - 클래스별 개별 EDA 필요 (유사성/특이점)
 - 유형별 특징 확신도(높음/중간/낮음) 판단 기준 자체가 불명확 → 기준을 먼저 정의하고 그에 따라 재분류 ⇒ **판정 기준: 높음 = Recall ≥ 0.7 AND 다른유형 혼동율 ≤ 0.10 / 낮음 = Recall < 0.4 OR 다른유형 혼동율 > 0.25 / 나머지는 중간**
 - 유형당 100건은 극소 표본 → 배수 · 중앙값이 우연 변동에 취약, 대안 필요 ⇒ **CTGAN 등 합성데이터 생성**
 - ML 모델링 :
 - 극단적 불균형에서 단일 모델(한방 LightGBM)만으로 전 클래스 커버하는 데 구조적 한계 지적 → 규칙 기반 + ML 결합 검토 권장 ⇒ **모델링 규칙기반 + ML 결합 파트 결론 단일모델에 비해 성능이 떨어짐**
 - `Amount_vs_monthly_max_ratio` 치명적 지적: 거래 시점엔 해당 월이 안 끝났으므로 '월간 최대'를 알 수 없음 → 미래 참조(look-ahead) 오류. 전월 기준 또는

시점까지 누적 최대값으로 재설계 필요 ⇒ **명세서 상 거래기준 1달 이전으로 명시**

- 파생변수 근거 서술이 전부 "재확인/스토리 보강/사실상 확정" 톤 → 라벨을 아는 전체 데이터에서 피처를 설계하고 같은 데이터로 검증한 순환논리. 진짜 근거는 (1) 시간분할/홀드아웃에서의 lift, (2) 실제 모델의 SHAP/importance여야 함
- "0.7103이 어느 데이터의 수치인지 인지가 안 됨" ⇒ **PPT 작성시 어느 데이터의 수치인지 표기 필수**

○ 결과 해석 :

- 비용 비대칭을 문제정의에서 강조해놓고 모델 비교는 순수 성능(Macro-F1)으로만 함 → 모델 비교 단계부터 비용 반영 필요
- RAG의 환각(hallucination) 위험 → 근거 문서 인용, 사람 검수 단계를 최소한 줄이라도 명시 필요

● 종합

- "정상 과차단 방지" vs "13유형 정확 탐지"는 trade-off 관계 → 각각 구체적 임계값 필요
- 핵심은 탐지이지 최고 모델이 아님 — ML이 유일한 수단이 아님을 상기
- FN 1,700만원 고정값 개선은 좋으나, 운영 환경에서는 정답을 실시간으로 알 수 없음 → 그 제약 하에서 모델이 실제로 어떻게 작동하는지 시나리오 설계 보완 필요
- 평가의 독립성: 임계값 스캔·합성데이터가 평가셋에 스며들지 않았음을 명시하고, 0.7103이 정확히 어느 데이터 기준인지 못 박기
- 성능의 해부: 클래스별 F1(특히 d·g) + 합성데이터 QA 결과를 본문으로 끌어올려 Macro-F1 0.71의 구성을 투명하게 공개
- 자동화의 책임성: RAG 환각 통제 + 알림 시스템 운영 부하를 한 장으로 다룰 것



결과

