



[규칙 기반 + ML결합](2차 전처리) (1)



Task :



실행 및 진행 사항 정리

[누수 제거] 정답 라벨 컬럼 ['is_fraud'] 자동 제외

[하이브리드] 규칙 기반 + ML 결합 — [기준: 피쳐 60개 · valid 홀드아웃 23,860행]

[데이터] train (96140, 60) / valid (23860, 60) | 정상=12(m)

[1] 규칙 자동 발굴

[규칙 발굴] 단일 조건 후보 71개 → 유형별 2~3개 조합 탐색

[유형별 최고 달성 가능 규칙 (train)]

a: precision=0.002 hits=5039

Access_Medium==1 & Transaction_is_withdrawal==1 & Flag_deposit_more_than_tenMillion==1

b: precision=0.060 hits=512

Customer_rooting_jailbreak_indicator==1 & Account_amount_daily_limit==1000000 & Transaction_is_withd

c: precision=0.021 hits=1216

Customer_flag_terminal_malicious_behavior_6==1 & Transaction_is_withdrawal==1 & Channel==0

d: precision=0.012 hits=1139

Transaction_is_withdrawal==1 & unused_terminal_and_internet==1 & Account_account_type==0

e: precision=0.027 hits=2829

Channel==0 & Transaction_is_withdrawal==1 & Flag_deposit_more_than_tenMillion==1

f: precision=0.030 hits=1048

Transaction_is_withdrawal==1 & Flag_deposit_more_than_tenMillion==1 & Customer_inquiry_atm_limit==0

g: precision=0.014 hits=1684



...

i: 0.70 → 0.70

j: 0.47 → 0.47

k: 0.71 → 0.71

l: 0.17 → 0.17



=====

[누수 제거] 정답 라벨 컬럼 ['is_fraud'] 자동 제외

[하이브리드 강화판] 규칙 + ML — [기준: 피처 60개 · valid 홀드아웃 23,860행]

[데이터] train (96140, 60) / valid (23860, 60) | 정상=12(m)

[1] 규칙 후보 발굴

[후보] atom 189개 (범주형+연속형분위수+검증파생) → 유형별 조합 탐색



[유형별 최고 달성 가능 precision (train)]

a: precision=0.933 hits=15 | Distance>=301.348 & Time_difference_seconds<=1935 & Access_Medium==1

b: precision=0.211 hits=19 | Amount_vs_remaining_balance>=1.79923 & Customer_rooting_jailbreak_indicator==1 &
c: precision=0.105 hits=38 | Amount_vs_remaining_balance>=1.79923 & Customer_flag_terminal_malicious_behavior
d: precision=0.062 hits=162 | Transaction_is_withdrawal==1 & Amount_vs_daily_limit>=10.6 & unused_terminal_and
e: precision=0.167 hits=30 | Amount_vs_remaining_balance>=1.79923 & large_deposit_and_remote_control==1 & Cus
f: precision=0.200 hits=30 | Amount_vs_remaining_balance>=1.79923 & Account_initial_balance>=3.02874e+07 & Cu
g: precision=0.074 hits=27 | Account_balance<=2.78403e+06 & Amount_vs_daily_limit>=10.6 & Customer_credit_rat
h: precision=0.172 hits=64 | Transaction_is_withdrawal==1 & Account_one_month_max_amount<=20000 &
Account_bal
i: precision=0.096 hits=239 | Transaction_Amount_abs>=5.092e+07 & Transaction_is_withdrawal==1 & Account_relea
j: precision=0.069 hits=609 | Amount_vs_remaining_balance>=1.79923 & Transaction_history_with_the_account<=0 &
k: precision=0.133 hits=30 | Number_of_transaction_with_the_account>=2 & Amount_vs_daily_limit>=10.6 & Accoun
l: precision=0.118 hits=17 | Customer_Birthyear<=1955 & Account_balance<=2.78403e+06 & Transaction_Amount_abs
...
i: 0.70 / 0.70 / 0.70
j: 0.47 / 0.47 / 0.47
k: 0.71 / 0.71 / 0.71
l: 0.17 / 0.17 / 0.17

60 features | valid 23,860 rows (hold-out)

Rule adoption threshold scan (rules mined on train)



[결론]

일부 기준/방식에서 성능이 변함(위 스캔 표 참고). 다만 방향(개선/악화) 확인 필요.

사기 비율 1.08% (극단 불균형) → 단순 규칙은 정밀도 한계.

모든 수치 기준: 피쳐 60개 · valid 홀드아웃 23,860행 · 규칙은 train에서만 발굴

연속형 분위수까지 규칙 후보에 넣어 재탐색한 결과, a유형은 고정밀 규칙(valid precision 0.9)이 존재했으나 ML이 이미 완벽히 커버해 override는 -0.003, boost는 0. 나머지 유형은 규칙 precision 6~21%로 결합 이득이 없음.

즉 하이브리드 프레임은 완성했고 규칙도 실제로 발굴되지만, 이 데이터에선 ML이 이미 규칙 영역을 흡수하고 있어 ML 중심이 타당함. 3차 전처리(as-of 파생)에서 유형별 신호가 강해지면 이 프레임이 자동으로 규칙을 채택·결합함."

바뀐 점

1. **연속형 분위수 규칙** — `Distance>=q95` 같은 조건 추가 → 이게 핵심이었어. 이걸 넣으니 **a유형 규칙**이 발굴됨 (`Distance≥301 & Time_diff≤1935 & Access_Medium==1`, train precision 0.93 / **valid에서도 0.86~0.90**)
2. **검증 파생변수 직접 투입** — `large_deposit_and_remote_control` 등을 최우선 후보로 (e-f유형 조합에 실제로 등장)
3. **precision 기준 스캔(0.85 → 0.3)** — 각 기준에서 규칙 수·성능 diff를 표로
4. **boost(소프트 결합)** — override와 나란히 비교



결과