

[생성 AI합성 데이터 / 증강 전후 비교]생성증강_비교 (2차 전처리 데이터, 3차 전처리 데이터)

Task :

 실행 및 진행 사항 정리

2차 전처리 데이터

[증강 비교] 동일 검증셋 (train만 증강)



방식 Macro_F1 사기평균Recall ΔMacro_F1

baseline	0.6053	0.5734	0.0000
+CTGAN	0.5441	0.5290	-0.0612
+TVAE	0.5199	0.4955	-0.0854
+SMOTE	0.5803	0.5532	-0.0250

[결론] 최고: baseline (Macro-F1 0.6053) | baseline 대비 +0.0000

→ 어떤 증강도 baseline을 못 넘음: 소수유형(70~80건) 자체가 적어 생성모델도 한계.

※ SMOTE는 규칙기반이라 DAICON 최종제출 불가(참고치). CTGAN/TVAE만 제출 후보.



생성 AI 합성데이터 증강 전/후 비교 분석 (ML 파트) 실험 환경 및 평가 독립성

- 데이터: 2차 전처리 완료 데이터 (`is_fraud` 제거, Validation 홀드아웃 23,860행)
- 증강 적용: Train 데이터셋에만 적용 (Valid 데이터셋은 원본 유지하여 엄격한 검증)

1. 실험 방법

실험 목적

- 소수 사기 유형(a~l)의 데이터 수가 유형당 70~80건 수준으로 극단적으로 불균형한 상황에서, 생성 AI 기반 합성데이터 증강이 Macro-F1 성능 향상에 기여하는지 검증

실험 방법

- **증강 기준:** 소수 사기 유형(a~l)을 각각 **500건까지 증강** 후 LightGBM 재학습
- **비교 대상 (4종):**
 1. **Baseline** : 증강 미적용 (기준점)
 2. **+CTGAN** : 생성형 AI 모델 (제출 가능)
 3. **+TVAE** : 생성형 AI 모델 (제출 가능)
 4. **+SMOTE** : 규칙 기반 이웃 보간법 (참고용, 규칙 기반이라 제출 불가)

2. 실험 결과 (동일 검증셋 평가)

증강 방식	유형	Macro-F1	사기 평균 Recall	Δ Macro-F1
Baseline	미증강 (기준)	0.6053	0.5734	0.0000
+CTGAN	생성형 AI	0.5441	0.5290	-0.0612
+TVAE	생성형 AI	0.5199	0.4955	-0.0854
+SMOTE	규칙 기반 (참고)	0.5803	0.5532	-0.0250

핵심 결과: 모든 증강 방식이 **Baseline**보다 낮은 성능을 기록함. (원본 그대로 학습한 **Baseline**이 0.6053으로 가장 우수)

3. 결과 해석 & 원인 분석

1. 생성형 모델(CTGAN/TVAE)의 큰 성능 하락

- 원본 소수 유형 데이터(70~80건)가 너무 적어 **생성 모델이 진짜 데이터 분포를 학습하지 못함**
- 학습되지 않은 합성데이터가 오히려 **결정 경계(Decision Boundary)**를 흐리는 노이즈로 작용

2. 클래스별 성능 불균형 (Trade-off 발생)

- **c, d** 등 일부 소수 유형은 CTGAN 적용 시 성능이 소폭 상승했으나, 기존에 우수했던 주요 유형(**a, k, h**)의 성능이 크게 감소하여

전체적으로 손실 발생

3. 오버샘플링 계열 전반의 한계

- 전통적인 규칙 기반 증강 방식인 **SMOTE** 역시 성능이 악화(\$-0.0250\$)되어, **현재 데이터 구조에서는 데이터 오버샘플링 방식 자체가 유효하지 않음**을 확인

3차 전처리 데이터

[증강 비교] 동일 검증셋 (train만 증강)

- -- +SMOTE (규칙기반·참고용) ---
[SMOTE] 20942 → 26000행 (k_neighbors=5)
[+SMOTE] Macro-F1=0.5739 | 사기유형 평균Recall=0.5465


방식	Macro_F1	사기평균Recall	ΔMacro_F1
----	----------	------------	-----------

baseline	0.6056	0.5732	0.0000
+CTGAN	0.4716	0.4599	-0.1340
+TVAE	0.4890	0.4766	-0.1166
+SMOTE	0.5739	0.5465	-0.0317

[결론] 최고: baseline (Macro-F1 0.6056) | baseline 대비 +0.0000

→ 어떤 증강도 baseline을 못 넘음: 소수유형(70~80건) 자체가 적어 생성모델도 한계.

※ SMOTE는 규칙기반이라 DAICON 최종제출 불가(참고치). CTGAN/TVAE만 제출 후보.



생성 AI 합성데이터 증강 전/후 비교 분석 (ML 파트 — 3차 기준)

실험 환경 및 평가 독립성

- 데이터셋: 3차 전처리 · 58개 피쳐 · `is_fraud` 제거 · Validation 홀드아웃 23,860행
- 증강 조건: Train 데이터셋에만 적용 (정상 데이터 20,000건 다운샘플링, Validation셋은 원본 유지하여 엄격 검증)
- ⚠ 참고사항: Look-ahead 의심 피쳐 5개 포함 상태 (as-of 재설계 전)

1. 실험 목적 & 방법

실험 목적

- 소수 사기 유형(a~l)의 데이터 수가 유형당 70~80건 수준으로 극단적으로 불균형한 상황에서, 생성 AI 기반 합성데이터 증강이 Macro-F1 성능 향상에 기여하는지 검증

실험 방법

- 증강 기준: 소수 사기 유형(a~l)을 각각 500건까지 증강 후 LightGBM 재학습
- 비교 대상 (4종):

1. **Baseline** : 증강 미적용 (기준점)
2. **+CTGAN** : 생성형 AI 모델 (제출 가능)
3. **+TVAE** : 생성형 AI 모델 (제출 가능)
4. **+SMOTE** : 규칙 기반 이웃 보간법 (참고용, 규칙 기반이라 제출 불가)

2. 실험 결과 (동일 검증셋 평가)

[3차] 실측 결과 (300트리 기준)

증강 방식	유형	Macro-F1	사기 평균 Recall	Δ Macro-F1
Baseline	미증강 (기준)	0.6056	0.5732	0.0000
+CTGAN	생성형 AI	0.4716	0.4599	-0.1340
+TVAE	생성형 AI	0.4890	0.4766	-0.1166
+SMOTE	규칙 기반 (참고)	0.5739	0.5465	-0.0317

핵심 결과 : 3차 전처리 데이터에서도 모든 증강 방식이 Baseline(0.6056)보다 낮은 성능을 기록함. 특히 생성형 AI(CTGAN/TVAE)의 성능 하락 폭이 크게 확대됨.

[2차 vs 3차] 회차별 증강 효과 비교 (참고)

증강 방식	2차 Macro-F1	2차 Δ F1	3차 Macro-F1	3차 Δ F1
Baseline	0.6053	0.0000	0.6056	0.0000
+CTGAN	0.5441	-0.0612	0.4716	-0.1340
+TVAE	0.5199	-0.0854	0.4890	-0.1166
+SMOTE	0.5803	-0.0250	0.5739	-0.0317

3. 결과 해석 & 원인 분석

1. 생성형 모델(CTGAN/TVAE)의 심화된 성능 하락

- 원본 소수 유형 데이터(70~80건)의 표본 수가 절대적으로 부족하여 생성 모델이 진짜 데이터 분포를 학습하지 못함
- 품질이 낮은 합성데이터가 결정 경계(Decision Boundary)를 흐리는 강한 노이즈로 작용함

2. 클래스별 성능 불균형 (Trade-off 발생)

- **c**, **d** 등 일부 소수 유형은 CTGAN 적용 시 성능이 소폭 상승했으나, 기존에 분류 성능이 좋았던 주요 유형(**a**, **k**, **h**)의 성능이 크게 떨어져 전체 성능은 오히려 큰 손실 발생

3. 오버샘플링 기법 전반의 한계

- 전통적인 규칙 기반 증강 방식인 **SMOTE** 역시 2차(\$-0.0250\$) 및 3차(\$-0.0317\$) 모두 성능이 악화되어, 현재 데이터 구조에서는 데이터 오버샘플링 계열 전체가 유효하지 않음을 재확인

