



EDA 중간 보고서

[템플릿 활용 가이드]

이 템플릿은 프로젝트 진행 상황을 점검하고, 앞으로의 계획을 정리하기 위한 목적으로 작성되었습니다.
템플릿 내 예시는 단순 참고용이며, **팀의 프로젝트 방향과 내용에 맞게 수정이 필요합니다.**

▼ 활용 방법

1. 템플릿의 구성을 확인하고 팀의 프로젝트에 맞게 내용을 작성합니다.
2. 작성한 중간 보고서를 기한 내 제출하여 튜터님께 피드백을 요청하고 답변을 받습니다.
3. 답변 받은 피드백 내용을 정리하고, 이후 프로젝트 진행 단계에 반영합니다.

1 프로젝트 개요

- **프로젝트 이름:** 온라인 거래 이상탐지 시스템(FDS) 구축
- **분석 목적:** 온라인 금융 거래 데이터에서 정상 거래와 13개 유형의 사기 거래(a~l, 정상 m)를 구분하는 요인을 규명하고, 데이터 기반 파생변수 설계 근거를 확보하여 사기 탐지 분류 모델의 성능을 개선함과 동시에, 데이터 QA(품질 점검·분할 전략·누수 방지) 프로세스를 체계화하는 것을 목적으로 함
- **데이터 출처:** 데이콘 대회용 온라인 거래 데이터
- **분석 대상 및 범위:** 전체 120,000건 거래 데이터 (정상 118,800건 / 사기 12개 유형 × 100건씩 1,200건), 65개 원본 컬럼 기준
- **예상 결과물:**
 - 모델링 결과: LightGBM/XGBoost/TwoStage Classifier 기반 13-class 분류 모델 (Macro F1 기준 평가)
 - 시각화 자료: 유형별 수치 프로파일 히트맵, 플래그 발생률 비교, 범주형 변수별 사기율 분석
 - 인사이트 요약: 유형별(a~l) 특징 변수 및 채널·매체 편중 분석을 통한 사기 수법 가설
 - 산출물: 전처리 파이프라인 문서화, 파생변수 근거표, Streamlit 대시보드

2 데이터 개요

- **데이터셋 설명**
 - **데이터 수집 방법:** 데이콘 대회용 온라인 거래 로그 데이터
 - **데이터셋의 크기:** 120,000행 × 65개 컬럼
 - **주요 변수 및 설명:** (예: 표 참고)

변수명	설명	데이터 타입
Fraud_Type	타겟 변수 — 정상(m) 및 사기 유형 12종 (a~l)	범주형 (13-class)
Customer_identification_number	주민번호(암호화)	범주형 (고유 4,101명)
Account_account_number	계좌 번호(암호화)	범주형 (고유 4,101개, 고객당 1개 좌)

변수명	설명	데이터 타입
Transaction_Amount	거래 금액 (부호 있음: 음수=출금, 양수=입금)	수치형
Transaction_Datetime	거래 일자	datetime
Account_balance	거래 후 계좌 잔액	수치형
Time_difference	거래 간격	timedelta
Distance	직전 거래 발생지와의 거리	수치형
Channel	거래 채널 (ATM/mobile/internet/Others)	범주형
Access_Medium	거래 시스템 접근 매체(a~h, 8종)	범주형

◦ Access_Medium 코드 정의

값	의미
a	ID/PW 로그인
b	패턴
c	생체로그인
d	금융/공동 인증서
e	사실인증서
f	보안카드
g	OTP
h	보안카드+OTP

• 데이터 전처리 과정

◦ 결측치 처리 방법:

- 원본 데이터 자체의 결측은 0건
- Time_difference_seconds(거래 일시 초 단위) 파생 과정에서 음수 156건(비물리적 값) 발견 → 절댓값 대신 NaN처리
- 파생 변수 과정에서 분모 0 으로 인해 발생한 결측 : `amount_to_month_max_ratio` (9.0%), `balance_depletion_ratio` (3.4%), `amount_to_balance_ratio` (1.3%)
"분모 자체가 0"이라는 의미있는 신호로 간주

◦ 이상치 탐지 및 조치:

- `Transaction_Amount`, `Account_initial_balance`, `Account_balance` 에서 음수값 발견 (각각 29.85%, 3.46%, 1.38%) → 오류가 아니라 입출금 방향 정보로 판단, 절댓값 컬럼(`Transaction_Amount_abs`)과 출금 여부 플래그(`Transaction_is_withdrawal`)로 부호 분리
- `Transaction_Datetime` 의 32.6%가 2025년 이후(최대 2058년)의 비현실적 미래 날짜로 확인 → 시간 순서 자체가 무의미하다고 판단, 시간 기반 분할 대신 층화 그룹 분할(StratifiedGroupKFold) 채택 근거로 사용

◦ 데이터 변환 :

- `Transaction_Amount_log`, `distance_log` : 우측 편향된 금액·거리 분포에 로그 변환 적용
- `Fraud_Type` 등 범주형 변수는 인코딩 이전 단계(1차 EDA)에서는 원본 라벨 상태로 유지 — 인코딩 후에는 의미 해석이 어려워지므로, 변별력 탐색은 반드시 인코딩 전에 수행

3 탐색적 데이터 분석(EDA)

1. 기술 통계 분석

- 주요 변수의 분포


변수	특성
Time_difference_seconds	평균 757,856초, 표준편차 20,038,430초로 극단적 왜도. 중앙값은 9,169초(약 2.5시간)
유형별 Time_difference_seconds 중앙값	a형 3,222초로 가장 짧음, h형 161,564초로 가장 김 → 두 유형 모두 변별력 있는 신호로 확인
고객/계좌 구조	고유 고객 4,101명 = 고유 계좌 4,101개 (1:1 대응), 고객당 평균 거래 29.3건
정상·사기 교차 고객	사기 행 1,200건 중 고유 고객 1,067명, 이 중 966명이 정상 거래에도 등장 → 랜덤 분할 시 심각한 누수 위험 확인

- 0/1 플래그 발생률 차이(정상 vs 사기, 상위순위)


순위	플래그
1	Transaction_is_withdrawal (출금 입금 여부 1=출금, 0 = 입금)
2	Flag_deposit_more_than_tenMillion (7일 거래내역 중 1천만원 이상 입금 여부)
3	Account_release_suspension (30일 이내 계좌 정지 해제 여부)
4	Customer_rooting_jailbreak_indicator (기기 루팅(안드로이드)/탈옥(ios)여부 플래그)

2. 데이터 시각화

- 유형별 주요 수치변수 프로파일 히트맵(z-score) : Fraud_Type별 8개 핵심 수치변수(거래금액, 잔액, 한도, 거리, 시간차, 거래이력 등) 중앙값을 열별 정규화하여 시각화




- 정상 vs 사기 플래그 발생률 차이




- Fraud_Type × 범주형 비율 히트맵


[Customer_credit_rating] Fraud_Type별 범주 분포 히트맵
상위 6개 범주 기준




[Channel] Fraud_Type별 범주 분포 히트맵
상위 4개 범주 기준




[Account_account_type] Fraud_Type별 범주 분포 히트맵
상위 4개 범주 기준



[Operating_System] Fraud_Type별 범주 분포 히트맵
상위 6개 범주 기준



- Fraud_Type별 플래그 발생률 히트맵



3. 패턴 및 트렌드

- 시간 관련 : Transaction_Datetimedml 32.6%가 2025년 이후 미래 날짜 (최대 2058년) → 시간 기반 분할 대신 층화 그룹 분할 채택

거래 발생 년도	거래 횟수
2052	3
2053	7
2054	11
2055	1
2056	1
2058	2

- 변수 간 상관관계 :
 - Customer_identification_number - Account_account_number 상관계수 1.0(완전중복)

고유 고객 수: 4,101
 고유 계좌 수: 4,101
 고객당 평균 거래수: 29.3

고객당 계좌 수 분포:

고객당 계좌 수	고객수
1	4101

- train / vaild 분할 관련 : 정상/사기 양쪽에 해당하는 고객이 있을 경우 랜던 분할 시 누수 위험



사기 행 수: 1,200
 사기에 등장한 고유 고객 수: 1,067
 정상·사기 양쪽에 등장하는 고객 수: 966

- 같은 고객이 train/vaild 양쪽에 들어가면 누수가 발생할 위험 → '층화' vs '고객단위 그룹 분할' 결정 필요

- Time_difference(_seconds) 정의 탐색 : 직전 거래와의 시간차이 컬럼에서 음수가 발생

→ 직전 거래와의 시간 차이이기 때문에 음수 처리를 할 필요성 ↑

음수 건수: 156
음수 최소(초): -1045256012.0
음수 최소(일 환산): -12097.9

Fraud_Type	count
m	154
a	2

	Time_difference	Time_difference_seconds
74	-11381 days +21:39:31	-983240429.0
84	-7993 days +05:48:41	-690574279.0
111	-8775 days +10:23:42	-758122578.0
208	-1971 days +07:08:21	-170268699.0
224	-1536 days +15:53:02	-132653218.0

- 현실적인 수치로 생각하면 직전 거래와의 시간 차이 컬럼에서 음수가 나올수 없으므로 관련 있는 컬럼들 간의 관계를 확인하여 컬럼 정의 탐색
- 모든 가설(컬럼쌍 최대 ~12%, 직전거래 ~6% 이하)이 실패 → `Time_difference_seconds` 는 datetime 컬럼들로 복원 불가능한 합성 생성값. 단, 유형별 중앙값에서 `a` ($\approx 3,222$ 초)·`h` ($\approx 161,564$ 초)가 뚜렷이 갈려 변별력이 있으므로 드롭하지 않고 보존. 음수 156건(대부분 정상 m, 최소 ≈ -33 년)은 비물리적이므로 절댓값 대신 결측(NaN) 처리 → LightGBM으로 결측치를 분기로 흡수

Fraud_Type	Time_difference_seconds
a	3222.0
b	8815.0
c	8451.5
d	9166.0
e	8594.5
f	7411.5
g	8669.0
h	161564.0
i	9403.0
j	7126.5
k	6260.5
l	8218.0
m	9186.0

4. 주요 인사이트 도출

- 유형별 특징 변수 요약:

유형	최대 z-score	특징 변수	채널/매체 결정성	명세서 기반 수법 가설
a	3.31	Distance, far_distance_flag	-	원거리/이례적 지역 접속 이상거래
b	3.28	device_network_risk_count	-	기기 변조·네트워크 우회 계정 탈취
c	2.84	terminal_malicious_count	-	원격제어·피싱·키로깅 등 복합 계정 탈취 수법

유형	최대 z-score	특징 변수	채널/매체 결정성	명세서 기반 수법 가설
d	0.78	뚜렷한 신호 없음	채널 고르게 분산	가설 도출 어려움
e	2.86	days_since_last_atm	ATM 100%	ATM+보안카드 인증 기반 휴면계좌 재활성화
f	2.88	days_since_last_branch	Others 100%	영업점 등 특수 채널을 통한 장기방치 계좌 고객 인출
g	1.02	뚜렷한 신호 없음	채널 고르게 분산	가설 도출 어려움
h	3.02	Time_difference_seconds	-	짧은 시간 간격 연속거래(자동화 인출)
i	3.31	amount_to_balance_ratio 등 금액계열	-	한도소진형 고객 이체
j	2.72	suspended_recipient_and_withdrawal	-	대포통장 이체 사기
k	3.10	Number_of_transaction_with_the_account	-	기존 거래관계를 이용한 반복 편취
l	3.09	account_age_days, auth_change_count	-	장기 고객 계좌 대상 인증수단 변경 후 탈취

- 타겟 분포 자체가 극심한 불균형(정상 99% vs 사기 12개 유형 각 0.083%) — 이 분포 하나만으로도 Accuracy 같은 단순 정확도 지표는 왜곡될 수밖에 없는 구조임을 EDA 단계에서 확인. 이후 **Macro F1을 주 평가지표**로 채택
- i, j 유형은 파생변수 설계 의도와 정확히 일치 — z-score 프로파일에서 j 유형이 `suspended_recipient_and_withdrawal`, `new_recipient_and_large_amount` 에서 튀는 것이 "대포통장 이체 사기" 설계 가설과 100% 부합
- e, f 유형은 채널이 필요조건 — 채널/매체 교차분석 결과 "이 유형이면 반드시 이 채널"이라는 방향의 결정론적 신호 (ATM 100%, Others 100%) 확인
- d, g 유형은 현재 피쳐로 설명 불가 — z-score 최대값이 각각 0.78, 1.02로 다른 유형(2.7~3.3대)과 확연히 낮고, 채널/매체 분포도 고르게 분산되어 있어 수치·플래그·범주형 어느 축에서도 유의미한 편중을 찾지 못함. 26개 파생변수의 설계 범위(시간·금액·위험·관계) 밖에 있는 신호일 가능성을 시사

4 현재까지의 진행 상황

- 진행한 작업
 - 데이터 품질 점검 완료 (UTF-8 BOM, 결측치 0건, 형식 검증 전부 위반 0건)
 - 컬럼 타입 명시 분류 완료 (`COL` 디셔너리로 datetime 6종·timedelta·수치형·범주형 직접 지정)
 - 음수값 처리 완료 (입출금 방향 정보로 판단, 절댓값+방향 플래그 분리)
 - `Time_difference_seconds` 정의 탐색 및 처리 완료 (복원 불가능한 합성값으로 결론, 변별력 확인되어 보존)
 - 분할 전략 확정 및 검증 완료 (StratifiedGroupKFold, 고객/계좌 누수 0건, 13개 클래스 양쪽 존재 확인)
 - 1차 EDA(파생 전) 완료
 - 26개 파생변수 생성 완료 (시간·금액·위험·관계 4개 영역)
 - 모델 베이스라인 비교 완료 (LightGBM/XGBoost/TwoStage 최종 후보 선정)
- 해결된 문제
 - 자동 키워드 매칭으로 인한 datetime 오분류 문제 → 명시적 리스트 고정으로 해결
 - `customer_age_days`, `account_age_days`, `Error_CodeTransaction_Failure_Status` 완전 중복 확인 → 드롭 결정

- 고객 단위 데이터 누수 위험 → StratifiedGroupKFold로 해결 및 검증 완료
- 컬럼명 기반 추정 정의의 정확성 문제 → 명세서 대조로 확정
- 부스팅 트리 계열 모델 선정 근거
 1. **클래스 불균형 대응**: `class_weight`, `scale_pos_weight` 로 소수 클래스에 직접 가중치 부여 가능. 배깅 방식(RandomForest)과 달리 이전 트리의 오차(주로 소수 클래스)에 다음 트리가 순차적으로 집중하는 구조라 불균형 데이터에 유리함
 2. **결측치 자동 처리**: `amount_to_month_max_ratio` (9.0%), `balance_depletion_ratio` (3.4%), `amount_to_balance_ratio` (1.3%) 등 분모 0으로 인한 의미 있는 결측을 자동으로 분기 기준에 반영. 반면 RandomForest/Logistic은 별도 Imputer가 필요해 결측 자체가 담고 있던 신호가 손실됨
 3. **스케일링 불필요**: 값의 순서만 사용하는 트리 구조 특성상, 거래금액(수백만 단위)과 플래그(0/1)를 스케일 조정 없이 함께 사용 가능 → 별도 스케일링 파이프라인 불필요
- **진행 중 문제**
 - 모델들을 선택한 선정 기준 부족
 - 파생변수 생성 시 근거부족
 - EDA로는 구분 못한 사기 유형 추정(특히 d, g 유형)

5 다음 단계 계획

- **추가로 분석할 내용**
 - **d, g 유형 설명력 확보를 위한 신규 피처 탐색**
 - 26개 파생변수(시간·금액·위험·관계)의 설계 범위 밖에 있는 신호를 찾기 위한 시퀀스 기반 피처 검토
 - 고객별 최근 N건 거래의 금액 변동성(표준편차, 급격한 증감)
 - 거래 간격의 규칙성 (붓/자동화 여부 판단)
 - `Customer_credit_rating`, `Operating_System` 등 아직 **d/g** 대상으로만 따로 안 본 범주형 변수 재검토
 - 단일 변수가 아닌 **조합(interaction) 효과** 탐색 (예: 특정 시간대 + 특정 채널 조합)
 - **모델링 준비**
 - 26개 파생변수 최종 확정 및 인코딩 적용
 - 피처 중요도(SHAP) 분석을 통한 변수 선택 근거 보강
- **예상 일정**
 - 7월 7일까지 2차 전처리 파일 제작 완료 예정(d, g 설명력 확보된)
 - 2차 전처리 파일 확보되는 대로 2차 모델링 실시 후 1차 전처리 파일 모델링 결과와 비교하여 추가작업 실행 예정
 - 대시보드 틀 및 n8n 연동은 이미 완료, 전처리 파일과 모델링 작업만 마무리되면 대시보드에 결과 분석 및 파일 넣기만 하면 최종 대시보드 완성(전처리와 모델링이 완료될때 까지 대시보드 담당자는 오류 수정 및 RAG AI 자연어 답변 업그레이드 예정)

6 부록

- **사용된 툴 및 라이브러리**
 - Python(pandas, matplotlib, seaborn 등)
 - Streamlit
- **참고 자료 및 출처**

- 데이터 출처

FSI AIxData Challenge 2024 : 생성 AI

출처 : DACON - Data Science Competition

 <https://dacon.io/competitions/official/236297/data>



- FDS관련 아티클

FDS(이상거래탐지시스템) | 토스페이먼츠 개발자센터

FDS는 'Fraud Detection System'의 준말로 거래 내역, 고객 정보, 평소 거래 패턴 등을 분석해서 의심되는 이상 거래를 탐지하고 차단하는 기술입니다.

 <https://docs.tosspayments.com/resources/glossary/fds>

 payments 개발자센터



- 데이터 명세서

[데이터 명세 및 생성조건.xlsx](#)

- 파생변수 근거표

[FDS 파생변수 근거표.md](#)

- 프로젝트 계획표


[FDS_WBS.xlsx](#)

- 기타 시각화 자료


- 프로젝트 전체 Flow Chart

온라인 거래 이상탐지 시스템(FDS) — 메인 파이프라인


도형 원칙: 타원=시작/종료, 평행사변형=입력/출력, 사각형=처리, 마름모=판단, 화살표=흐름



○ 파생변수 X 유형 히트맵




○ 파생변수 상관관계 히트맵



○ 주요 파생변수 분포 : 정상 VS 사기

주요 파생변수 분포: 정상 vs 사기



+ 튜터 피드백 정리

- 피드백 내용
 - (예: 특정 변수 간의 상관관계를 더 심도 있게 분석할 필요가 있음)
 - (예: 시각화를 통해 변수 간 패턴을 명확히 보여줄 필요가 있음)
- 반영할 내용 및 변경 사항
 - (예: 상관계수가 높은 변수 추가 분석 및 관련 시각화 생성)
 - (예: 데이터 전처리 과정에서 추가적인 데이터 변환 작업 수행)
- 남은 과제 및 추가 계획
 - (예: 튜터님이 제안한 모델링 접근법 시도)
 - (예: 외부 데이터 결합 여부 검토 후 분석 계획 조정)